


Mediana E2E jako suma TTFT i czasu generacji



Run z zimnym cache; słupki pokazują medianę w sekundach dla każdej kombinacji modelu i kwantyzacji.