


Mediana E2E jako suma TTFT i czasu generacji



Run z ciepłym cache; słupki pokazują medianę w sekundach dla każdej kombinacji modelu i kwantyzacji.