


Długość odpowiedzi a czas generacji



Każdy punkt to jedno żądanie z poprawnym generation_ms; liczba znaków jest tylko przybliżeniem, bo benchmark nie zapisywał liczby tokenów.