


Rozmiar GGUF a mediana czasu generacji



Etykiety punktów pokazują wariant kwantyzacji; oś Y używa mediany generation_ms z żądań z ciepłym cache.