


Mediana czasu generacji [ms] — warm cache, bez prefill



Mediana generation_ms = e2e_ms - ttft_ms; oś X pokazuje warianty kwantyzacji, a słupki modele.