


Szybkość generacji [tok/s] — warm cache, prefill wyizolowany



W danych nie ma pola tokens_per_s, więc wartości policzono jako answer_chars / (generation_ms / 1000), a następnie zmedianowano.