


Rozmiar GGUF a mediana modelu LN czasu generacji



Cold cache, $n \approx 100$. Model LN: wysokość słupka = mediana e^{μ} ; przedział = $e^{\mu \pm \sigma}$