


Czas generacji — mediana modelu LN według wariantu

Czas generacji [s]



Kwantyzacja

Q2_K

Q4_0

Q4_K_M

Q8_0

Warm cache, $n \approx 100$. Model LN: wysokość słupka = mediana e^{μ} ; przedział = $e^{(\mu \pm \sigma)}$