


Rozmiar GGUF a mediana modelu LN czasu generacji



Warm cache, $n \approx 100$. Model LN: wysokość słupka = mediana e^{μ} ; przedział = $e^{(\mu \pm \sigma)}$